

키워드 기반 학사 공지와 첨부문서 자동 수집·구조화 시스템 구현

Implementation of a Keyword-Based System for Automated Collection and Structuring of Academic Notices and Attachments

최하영
Hayoung Choi

동국대학교 AI융합대학 AI소프트웨어융합학부 컴퓨터공학전공

E-mail: hayo021111@naver.com

요약

대학의 학사 및 행정 정보는 일반적으로 학과 홈페이지의 공지사항을 통해 제공되며, 신청 일정과 제출 방법은 공지 본문에, 세부 목록과 신청 양식은 Excel 및 HWP 등의 첨부문서에 분산되어 있다. 이로 인해 사용자는 공지 본문과 여러 첨부파일을 개별적으로 확인해야 하며, 해당 정보를 웹 서비스나 다른 시스템에서 자동으로 활용하기도 어렵다.

본 연구에서는 사전에 정의된 키워드를 기반으로 관련 최신 공지를 자동으로 탐색하고, 공지 본문과 첨부문서를 수집·분석하여 구조화된 JSON 데이터로 변환하는 시스템을 구현하였다. 시스템은 공지 목록에서 키워드가 포함된 후보 공지를 탐색하고, 작성일과 공지 ID를 기준으로 최신 공지를 선택한다. 이후 상세 페이지의 본문과 첨부파일을 수집하고, 파일 형식에 따라 Excel 파서와 HWP 파서를 적용한다.

공지 본문에서는 신청 일정, 제출 장소, 제출 방법 및 필요 서류를 추출한다. Excel 문서에서는 교원명, 과목명, 연구내용, 수강정원 및 수강 자격사항 등의 목록 정보를 분석하며, HWP 문서에서는 신청서 입력 항목과 담당교수 서명란을 확인한다. 또한 연구내용과 수강 자격사항에서 기술 관련 표현과 신청 조건을 추출하여 검색과 필터링에 활용할 수 있는 파생 정보를 생성한다. 각 분석 결과는 하나의 JSON 스냅샷으로 통합하고, 이전 결과와 비교하여 공지와 첨부자료의 변경 여부를 확인한다.

시스템 검증을 위해 동국대학교 컴퓨터·AI 학부의 2026 학년도 여름학기 개별연구 신청 공지를 대표 사례로 적용하였다. 실행 결과 첨부파일 2개를 자동으로 수집하였으며, Excel 문서에서 총 43개의 연구 항목을 추출하고 HWP 문서에서 8개의 입력 필드와 1개의 담당교수 서명란을 확인하였다. 또한 Python 기반 단위 테스트 40개가 모두 통과하였다. 본 시스템은 단순한 HTML 수집을 넘어 관련 공지 탐색, 첨부문서 분석, 주요 정보 구조화 및 변경 비교를 하나의 처리 흐름으로 통합하였다는 점에서 차별성을 가진다.

키워드: 학사 공지, 키워드 기반 크롤링, 첨부문서 분석, Excel 파싱, HWP 파싱, JSON 구조화, 변경 비교

1. 서론

대학의 학사 및 행정 정보는 주로 학과 홈페이지의 공지사항을 통해 제공된다. 신청 일정, 제출 방법 및 유의사항은 공지 본문에 포함되며, 세부 목록이나 신청 양식은 Excel, HWP 등의 첨부문서로 제공되는 경우가 많다. 이에 따라 하나의 업무에 필요한 정보가 공지 본문과 여러 첨부파일에 분산되어 있다.

동국대학교 컴퓨터·AI 학부의 개별연구 신청 안내도 이러한 형태로 제공된다. 신청 마감일과 제출 방법은 공지 본문에서 확인해야 하며, 개설 연구 목록은 Excel 문서에, 수강신청원 양식은 HWP 문서에 포함되어 있다. 사용자는 공지와 첨부파일을 각각 열어 필요한 내용을 직접 확인하고 정리해야 한다.

웹 크롤링은 웹페이지의 제목, 본문 및 링크를 자동으로 수집하거나 특정 키워드가 포함된 게시물을 탐색하는 데 효과적이다. 그러나 공지의 핵심 내용이 첨부문서 내부에 포함된 경우에는 HTML 본문과 파일 링크를 수집하는 것만으로 전체 정보를 활용하기 어렵다. Excel의 표 데이터와 HWP의 신청 양식은 서로 다른 구조를 가지므로 각각의 문서 형식에 적합한 분석 과정이 추가로 필요하다.

또한 기존 크롤링 결과는 HTML 원문이나 첨부파일 형태로 저장되는 경우가 많아, 이를 연구 목록 검색, 신청 일정 안내, 제출 서류 확인과 같은 기능에 활용하려면 필요한 내용을 다시 정리해야 한다. 공지나 첨부파일이 수정된 경우에도 사용자가 기존 자료와 새로운 자료를 직접 비교해야 한다.

본 연구에서는 이러한 한계를 개선하기 위해 키워드를 기반으로 관련 최신 공지를 자동으로 탐색하고, 공지 본문과 첨부문서를 수집·분석하여 구조화된 데이터로 변환하는 시스템을 구현하였다. 시스템은 공지 목록에서 관련 키워드가 포함된 게시물을 탐색하고, 작성일과 공지 ID를 기준으로 최신 공지를 선택한다. 이후 공지 본문과 첨부파일을 수집하고, 파일 형식에 따라 Excel 파서와 HWP 파서를 적용한다.

공지 본문에서는 신청 일정, 제출 장소, 제출 방법 및 필요 서류를 추출한다. Excel 문서에서는 교원명, 과목명, 연구내용, 수강정원 및 수강 자격사항 등의 연구 목록을 분석하며, HWP 문서에서는 신청서의 입력 항목과 담당교수 서명란을 확인한다. 각 분석 결과는 하나의 JSON 데이터로 통합하고, 이전에 저장된 결과와 비교하여 공지와 첨부자료의 변경 여부도 확인할 수 있도록 하였다.

본 연구의 차별점은 일반적인 HTML 중심 크롤링을 넘어 관련 공지 탐색, 첨부문서 분석, 주요 정보 추출, JSON 구조화 및 변경 비교를 하나의 처리 과정으로 연결한 것이다. 시스템의 동작은 동국대학교 컴퓨터·AI 학부의 개별연구 신청 공지를 대표 사례로 적용하여 검증하였다. 개별연구 공지는 시스템의 동작과 적용 가능성을 검증하기 위한 대표 사례이며, 생성된 구조화 데이터는 연구 목록 검색, 신청 일정 안내, 제출 조건 확인 및 신청서 작성 지원 기능에 활용할 수 있다.

2. 관련 기술 및 기존 방식과의 차별성

2.1. 웹 크롤링과 공지 정보 수집

웹 크롤링은 웹페이지에 자동으로 접근하여 HTML 문서에서 필요한 정보를 수집하는 기술이다. 일반적으로 HTTP 요청을 통해 웹페이지를 가져오고, HTML 파서를 이용하여 제목, 본문, 게시일 및 링크 등의 요소를 추출한다[1,2].

대학 홈페이지의 공지사항에도 웹 크롤링을 적용하여 공지 목록과 상세 페이지의 정보를 수집할 수 있다. 공지 목록에서는 게시물 제목, 작성일 및 상세 페이지 주소를 확인할 수 있으며, 특정 키워드가 포함되어 있는지를 검사하여 관련 공지를 탐색할 수 있다.

이러한 방식은 HTML 페이지에 표시된 정보를 반복적으로 수집하는 데 효과적이다. 그러나 공지 후보가 여러 개일 때 키워드가 일치하는 후보 중 최신 공지를 선택하거나, 공지 제목의 띄어쓰기와 표현 차이를 고려하여 대상을 탐색하려면 별도의 기준이 필요하다.

또한 공지 상세 페이지에서 첨부파일 링크를 수집하더라도 파일 내부의 정보가 자동으로 분석되는 것은 아니다. 주요 내용이 Excel 이나 HWP 문서에 포함된 경우에는 첨부파일을 다운로드한 뒤 문서 형식에 맞는 추가 분석을 수행해야 한다.

2.2. 첨부문서 분석과 데이터 구조화

대학의 학사 및 행정 공지에서는 연구 목록, 교과목 정보 및 모집 인원과 같은 표 형식의 자료에 Excel 문서가 주로 사용된다. 반면 신청서와 행정 양식에는 텍스트, 표, 입력 항목 및 서명란을 포함할 수 있는 HWP 문서가 널리 사용된다.

Excel 의 .xlsx 와 .xlsm 파일은 Office Open XML 표준을 기반으로 하며, 문서 내부에 시트, 셀, 공유 문자열 및 병합 영역 등의 정보가 저장된다[3]. 따라서 표의 헤더와 데이터 행을 분석하면 문서에 포함된 목록 정보를 구조화된 형태로 추출할 수 있다.

HWP 문서는 OLE Compound File 구조와 *BodyText* 영역의 레코드를 분석하여 문서 내 텍스트와 표 정보를 확인할 수 있다[4]. 이를 통해 신청서에 포함된 입력 항목이나 서명란의 존재 여부를 파악할 수 있다. 다만 Excel 과 HWP 는 저장 구조가 서로 다르므로 동일한 방식으로 처리할 수 없으며, 각각의 형식에 적합한 파서가 필요하다.

문서별로 추출된 정보는 서로 다른 형태를 가지므로 하나의 서비스에서 활용하려면 공통된 데이터 구조로 변환해야 한다. JSON 은 객체와 배열을 이용하여 계층적인 데이터를 표현할 수 있고, 여러 프로그래밍 언어와 웹 서비스에서 쉽게 처리할 수 있다는 장점이 있다[5].

공지 기본 정보, 신청 일정, 제출 조건, 연구 목록 및 신청서 입력 항목을 JSON 으로 통합하면 원본 문서를 다시 열지 않고도 필요한 정보를 검색하거나 기능별로 활용할 수 있다. 또한 수집 시점별 결과를 별도의 JSON 스냅샷으로 저장하면 이전 결과와 새로운 결과를 비교하는 데 사용할 수 있다.

2.3. 기존 방식의 한계와 본 연구의 차별성

기존 웹 크롤링과 문서 분석 기술을 이용하면 웹페이지와 첨부문서의 내용을 각각 수집할 수 있다. 그러나 대학 공지처럼 필요한 정보가 공지 본문과 여러 첨부문서에 분산된 경우에는 수집 결과를 사용자가 다시 확인하고 통합해야 하며, 공지나 첨부파일이 수정되었을 때에도 기존 결과와 새로운 결과를 별도로 비교해야 한다.

본 연구에서는 이러한 과정을 하나의 시스템으로 통합하였다. 먼저 공지 목록에서 ‘개별연구’와 ‘개별 연구’ 등의 키워드를 기준으로 후보 공지를 탐색하고, 작성일과 공지 ID 를 이용하여 최신 공지를 선택한다. 선택된 공지에서는 본문과 첨부파일을 함께 수집하며, Excel 과 HWP 문서는 파일 형식에 따라 각각의 파서로 분석한다.

공지 본문에서는 신청 일정과 제출 정보를 추출하고, Excel 문서에서는 연구 목록을, HWP 문서에서는 신청서 입력 필드와 서명란을 확인한다. 추출된 정보는 공지, 일정, 제출 조건, 연구 목록 및 신청서 항목으로 분류하여 하나의 JSON 스냅샷으로 통합한다.

또한 새로 생성된 결과를 이전 스냅샷과 비교하여 공지 본문, 첨부파일 및 연구 항목의 변경 여부를 확인하도록 하였다. 이에 따라 사용자가 여러 문서를 직접 열어 정보를 정리하거나 변경 내용을 비교하는 과정을 줄일 수 있다.

따라서 본 시스템은 단순한 웹페이지 수집에 머무르지 않고 키워드 기반 최신 공지 탐색, 다양한 형식의 첨부문서 분석, 주요 정보의 구조화 및 변경 비교를 하나의 흐름으로 자동화하였다는 점에서 기존 방식과 차별성을 가진다. 이러한 기능을 구현하기 위한 시스템의 세부 구조와 단계별 처리 과정은 3 장에서 설명한다.

3. 시스템 설계 및 구현

3.1. 전체 시스템 구조

본 시스템의 전체 처리 과정은 그림 1 과 같이 학과 홈페이지 접근, 공지 목록 크롤링, 최신 관련 공지 탐색, 공지 본문 및 첨부파일 수집, 첨부문서 분석, 데이터 병합 및 구조화, JSON 스냅샷 생성의 일곱 단계로 구성된다.

먼저 사용자가 학과 홈페이지 주소를 입력하면 시스템은 공지 목록 페이지에 접근한다. 이후 사전에 정의된 개별연구 관련 키워드를 기준으로 후보 공지를 탐색하고, 작성일과 공지 ID 를 이용하여 최신 공지를 선택한다. 해당 공지의 상세 페이지에서 본문과 첨부파일 링크를 수집한다.

수집된 첨부파일은 확장자에 따라 Excel 또는 HWP 파서로 전달된다. Excel 파서는 연구 목록을 추출하고, HWP 파서는 수강신청원 양식의 입력 필드와 서명란을 분석한다. 공지 본문에서는 신청 일정과 제출 방법을 추출한다.

각 분석 결과는 하나의 공통 데이터 구조로 병합되며, 최종 결과는 JSON 스냅샷으로 저장된다. 생성된 JSON 은 향후 웹 서비스나 다른 행정정보 시스템의 입력 데이터로 활용할 수 있다.




그림 1. 키워드 기반 학사 공지 및 첨부문서 구조화 시스템의 전체 흐름

Fig. 1. Overall workflow of the keyword-based academic notice and attachment structuring system

3.2. 개별연구 공지 탐색

공지 탐색 단계에서는 학과 공지 목록 페이지를 순차적으로 요청한다. 각 공지 항목에서 제목, 공지 ID, 작성일 및 상세 페이지 정보를 추출한 뒤 제목에 개별연구 관련 키워드가 포함되어 있는지 검사한다.

본 시스템에서는 ‘개별연구’와 ‘개별 연구’를 주요 탐색 키워드로 사용하였다. 일반 목록 탐색에서 후보를 찾지 못한 경우에는 홈페이지의 제목 검색 기능을 이용하여 후보 공지를 추가로 탐색한다.

후보 공지가 여러 개 검색되는 경우 작성일과 공지 ID를 기준으로 가장 최근 공지를 선택한다. 이를 통해 사용자가 공지 번호나 상세 URL을 직접 입력하지 않아도 최신 개별연구 신청 공지를 자동으로 찾을 수 있다.

3.3. 공지 본문 및 첨부파일 수집

최신 공지가 선택되면 시스템은 공지 상세 페이지에 접근하여 제목, 작성자, 작성일, 본문 텍스트 및 첨부파일 링크를 수집한다.

공지 본문에서는 신청 마감일, 인터뷰 및 서류 제출 기간, 별도 수강신청 기간, 연구 수행 기간, 제출 장소 및 제출 방법과 같은 내용을 추출한다. 일정과 제출 조건은 정규표현식과 주요 문구 탐색을 이용하여 구조화한다.

첨부파일 링크는 파일별로 반복 처리된다. 각 첨부파일은 공지 ID를 기준으로 생성된 폴더에 저장되며, 원본 파일명, 파일 크기, 파일 형식 및 해시값 등의 메타데이터가 함께 기록된다.

다운로드가 실패하거나 지원하지 않는 파일 형식이 발견되면 해당 내용을 오류 정보로 기록하여 전체 크롤링 결과에서 확인할 수 있도록 하였다.

3.4. 첨부문서 분석

3.4.1. Excel 연구 목록 분석

Excel 파서는 연구 목록이 포함된 시트를 탐색한 후, 표의 헤더와 실제 데이터가 시작되는 행을 판별한다. 이후 각 행을 하나의 연구 항목으로 변환한다.

추출 대상은 다음과 같다.

개설학부, 교원명, 과목명, 학수강좌번호, 연구내용, 수강정원, 인터뷰 일정, 주당 연구시간, 수강 자격사항

또한 연구내용과 수강 자격사항에 포함된 주요 표현을 분석하여 기술 관련 키워드와 신청 조건을 파생 정보로 생성하였다. 사전 상담 필요 여부와 추가 신청 제한 여부도

별도 항목으로 구조화하였으며, 해당 정보는 향후 기술 키워드 기반 연구 목록 검색과 조건별 필터링에 활용할 수 있다.

실제 공지 Excel 첨부파일을 분석한 결과 총 43 개의 연구 항목이 추출되었다.

3.4.2. HWP 신청 양식 분석

HWP 파서는 문서의 텍스트와 표 구조를 분석하여 해당 문서가 개별연구 수강신청원인지 확인한다.

분석 결과 다음 8 개의 입력 필드를 확인하였다.

학년도 및 학기, 성명, 학번, 소속, 연락처, 교과목명, 연구주제, 담당교수

또한 담당교수 확인을 위한 서명란 1 개가 존재하는 것을 확인하였다. 해당 결과는 향후 신청서 작성 화면의 필수 입력 항목이나 자동채움 기준으로 활용할 수 있다.

현재 HWP 분석은 텍스트와 표 중심으로 구현되어 있으며, 문서의 모든 이미지, 도형 및 복잡한 서식을 완전하게 복원하는 기능은 포함하지 않는다.

3.5. 데이터 구조화 및 저장

공지 본문과 첨부문서에서 추출된 정보는 하나의 JSON 객체로 병합된다. 최종 JSON의 주요 구성은 다음과 같다.

표 1. 최종 JSON 스냅샷의 주요 필드

Table 1. Main fields of the final JSON snapshot

필드	내용
notice	공지 ID, 제목, 작성일, 본문 및 URL
schedule	신청 마감일, 인터뷰 기간, 수강신청 기간
submission	제출 장소, 제출 방법 및 필요 서류
attachments	첨부파일 메타데이터와 분석 상태
research_items	Excel에서 추출된 연구 목록
application_form	HWP에서 추출된 신청서 입력 필드
warnings	누락값 및 데이터 품질 관련 경고
errors	다운로드 또는 문서 분석 오류
comparison_status	이전 스냅샷과의 비교 결과 상태
changes	공지·첨부파일·연구 항목의 변경 내역

최종 결과는 수집 시점이 포함된 JSON 파일과 최신 결과를 나타내는 `latest.json` 파일로 저장된다.

또한 이전에 저장된 JSON 스냅샷과 새로 생성된 결과를 비교하여 공지 본문, 첨부파일 및 연구 항목의 변경 여부를 확인한다. 이를 통해 향후 공지 수정이나 첨부파일 교체를 감지할 수 있는 기반을 마련하였다.

4. 실험 및 결과

4.1. 테스트 환경

표 2. 시스템 테스트 환경
Table 2. System test environment

항목	내용
운영체제	Windows 11 Pro
실행 환경	PowerShell
CPU	12th Gen Intel Core i5-1240P
메모리	15.69 GB
Python	3.12.10
주요 Python 라이브러리	lxml 6.1.1
테스트 일자	2026 년 7 월 13 일
테스트 대상	공지 ID 1390, Excel 1 개, HWP 1 개

4.2. 테스트 방법

시스템 검증은 단위 테스트와 실제 홈페이지 크롤링으로 구분하여 수행하였다.

단위 테스트는 공지 목록 HTML 분석, 공지 상세 페이지 분석, 개별연구 공지 선택, 첨부파일 처리, Excel 문서 분석, HWP 문서 분석, 일정 및 제출 정보 구조화, JSON 스냅샷 비교와 같은 기능을 대상으로 하였다.

실제 크롤링 테스트에서는 학과 홈페이지를 입력으로 제공하고 다음 처리 과정이 정상적으로 수행되는지 확인하였다.

홈페이지 접근 → 최신 개별연구 공지 탐색 → 상세 본문 수집 → 첨부파일 링크 추출 → Excel 및 HWP 다운로드 → 파일별 파서 실행 → JSON 결과 저장

4.3. 테스트 결과

Python 단위 테스트의 실행 결과는 그림 2 에 제시하였다.

표 3. 대표 기능별 검증 결과

Table 3. Verification Results by Representative Functions

검증 항목	기대 결과	실제 결과	판정
Python 단위 테스트	전체 테스트 통과	40 개 중 40 개 통과	성공
최신 공지 탐색	최신 개별연구 공지 선택	공지 1390 번 선택	성공
공지 본문 수집	본문 추출	872 자 추출	성공
첨부파일 다운로드	Excel·HWP 2 개 다운로드	2 개 다운로드	성공
Excel 파서	연구 목록 추출	연구 항목 43 개 추출	성공
HWP 파서	입력 필드 및 서명란 확인	필드 8 개, 서명란 1 개	성공
JSON 생성	latest.json 생성	정상 생성	성공
변경 비교	비교 상태 생성	NO_CHANGES	성공
경고 및 오류 처리	경고를 기록하고 나머지 분석 계속 수행	경고 3 건, 오류 0 건	성공

실행 명령

```
$env:PYTHONPATH='src'; .\.venv\Scripts\python.exe -m unittest discover -s tests -v
```

주요 테스트 항목 일부

```
test_list_parser_uses_go_detail_id ... ok
test_detail_parser ... ok
test_excel_structure ... ok
test_hwp_application_form_fields_and_signatures ... ok
test_snapshot_detects_research_changes ... ok
test_download_failure_is_recorded_in_errors ... ok
```

전체 테스트
40개

실행 시간
0.365s

결과
OK

그림 2. Python 단위 테스트 실행 결과
Fig. 2. Python unit test execution results




그림 3. 공지 1390 번의 크롤링 및 첨부문서 분석 흐름
Fig. 3. Crawling and attachment analysis workflow for notice 1390

```
{
  "notice": {
    "notice_id": "1390",
    "title": "2026학년도 여름학기 개별연구 신청 안내
(~04/30(목)까지)",
    "written_at": "2026-04-23",
    "url":
"https://cs.dongguk.edu/article/notice/detail/1390"
  },
  "attachments": [
    {
      "name": "1. 2026-여름학기 개별연구 개설신청서(컴퓨터
·AI학과)_20260430.xlsx",
      "role": "INDIVIDUAL_RESEARCH_LIST",
      "extension": ".xlsx",
      "download_success": true,
      "parse_success": true
    },
    {
      "name": "2. 2026-여름학기 개별연구 수강신청원(학생
용).hwp",
      "role": "APPLICATION_FORM",
      "extension": ".hwp",
      "download_success": true,
      "parse_success": true
    }
  ],
  "schedule": {
    "application_deadline": {
      "value": "2026-04-30 17:00",
      "status": "CONFIRMED"
    }
  },
}
```

Source: data/snapshots/individual-research/latest.json

```
"course_registration_period": {
  "value": "5.13.(수)~5.15.(금)",
  "status": "CONFIRMED"
},
"research_period": {
  "value": "6.23.(화)~7.13.(월)",
  "status": "CONFIRMED"
}
},
"submission": {
  "location": {
    "value": "원흥관 423호",
    "status": "CONFIRMED"
  },
  "method": {
    "value": "방문 제출",
    "status": "CONFIRMED"
  },
  "required_documents": [
    {
      "name": "개별연구 수강신청원",
      "requirement_type": "REQUIRED"
    },
    {
      "name": "담당교수 승인 증빙",
      "requirement_type": "ONE-OF"
    }
  ]
}
}
```

그림 4. 대표 공지의 입력 데이터 및 크롤링 결과

Fig. 4. Input data and crawling results for the representative notice

4.4. 대표 사례 분석

대표 사례로 2026 학년도 여름학기 개별연구 신청 안내 공지(ID 1390)를 선정하였다. 크롤러는 동국대학교 컴퓨터·AI 학부 홈페이지의 공지 목록을 탐색하여 해당 공지를 키워드와 일치하는 최신 개별연구 공지로 선택하였다. 상세 페이지 분석 결과 공지 본문 872 자와 첨부파일 2 개의 다운로드 링크를 수집하였다. 대표 사례에 적용된 전체 크롤링 및 첨부문서 분석 과정은 그림 3 과 같다. 대표 공지의 입력 데이터와 크롤링 결과는 그림 4 에 제시하였다.

공지 본문에서는 신청 마감일을 2026 년 4 월 30 일 17 시로 확인하였다. 신청 마감일, 별도 수강신청 기간 및 연구 수행 기간 등의 일정 정보는 *schedule* 에 저장하고, 원흥관 423 호와 방문 제출로 확인된 제출 장소 및 방법은 *submission* 에 구조화하였다.

첫 번째 첨부파일인 Excel 연구 목록에는 총 43 개의 연구 항목이 포함되어 있었다. Excel 파서는 교원명, 과목명, 연구내용, 수강정원 및 수강 자격사항을 추출하고, 추가 신청 제한 여부와 사전 상담 필요 여부 등의 파생 정보를 생성하였다. 생성된 파생 정보는 향후 사용자가 연구 분야와 신청 조건을 기준으로 연구 항목을 검색하거나 필터링하는 데 활용할 수 있다. 추출된 대표 연구 항목과 파생 정보의 구조는 그림 5 와 같다.

두 번째 첨부파일인 HWP 수강신청원에서는 학년도 및 학기, 성명, 학번, 소속, 연락처, 교과목명, 연구주제, 담당교수의 8 개 입력 필드와 담당교수 서명란 1 개를 확인하였다. 신청 양식에서 추출된 입력 필드와 서명란 정보는 그림 6 에 제시하였다.

분석 결과는 *latest.json* 스냅샷으로 저장되었다. 전체 처리 과정에서 연구내용 누락 1 건과 동일 교수·과목명

중복 2 건이 경고로 기록되었으나 오류는 발생하지 않았으며, 전체 파싱은 정상적으로 완료되었다. 이전 스냅샷과 비교한 결과 *comparison_status* 는 *NO_CHANGES* 로 확인되었다.

```
{
  "research_item_count": 43,
  "sample_research_item": {
    "순번": 1,
    "교원명": "[교원명 익명화]",
    "과목명": "개별연구(CSC 생체신호를 이용한 혈압 추정)",
    "연구내용": "ECG PPG를 이용한 혈압 추정 및 reasoning",
    "수강정원": 2,
    "인터뷰 일정": "상시",
    "수강 자격사항": "연구실 학부연구생 전용입니다. 추가 신청 받지 않습니다. 이메일 보내지 말아주세요",
    "derived": {
      "추가 신청 불가 여부": true,
      "사전 상담 필요 여부": false,
      "인터뷰 또는 상담 필요 여부": false,
      "프로그래밍 언어": []
    }
  }
}
```

Source: data/snapshots/individual-research/latest.json

그림 5. 대표 Excel 연구 목록의 파싱 결과

Fig. 5. Parsing result of the representative Excel research list

```

{
  "document_title": "개별연구 수강신청원",
  "field_count": 8,
  "fields": [
    {
      "field": "academic_year_semester",
      "label": "학년도/학기",
      "required": true
    },
    {
      "field": "student_name",
      "label": "성명",
      "required": true
    },
    {
      "field": "student_id",
      "label": "학번",
      "required": true
    },
    {
      "field": "affiliation",
      "label": "소속",
      "required": true
    },
    {
      "field": "contact",
      "label": "연락처",
      "required": true
    },
    {
      "field": "course_name",
      "label": "교과목명",
      "required": true
    },
    {
      "field": "research_topic",
      "label": "연구주제",
      "required": true
    },
    {
      "field": "professor",
      "label": "담당교수",
      "required": true
    }
  ],
  "signature_count": 1,
  "required_signatures": [
    {
      "name": "담당교수 서명",
      "required": true
    }
  ]
}

```

Source: data/napshots/individual-research/latest.json

그림 6. 대표 HWP 수강신청원의 파싱 결과
Fig. 6. Parsing result of the representative HWP application form

5. 구조화 데이터의 활용 및 확장 가능성

본 연구에서 생성한 JSON 데이터는 개별연구 신청 정보를 한눈에 확인할 수 있는 웹 서비스의 기초 자료로 활용할 수 있다. 공지 본문에서 추출한 신청 일정과 제출 방법은 안내 화면에 표시하고, Excel 에서 추출한 연구 목록은 교수명, 과목명 및 연구주제 검색에 활용할 수 있다. 또한 HWP 에서 확인한 입력 항목은 신청서 작성과 필수값 검증에 사용할 수 있다.

구조화된 데이터의 활용 가능성을 확인하기 위해 간단한 웹 서비스를 시범적으로 구현하였다. 해당 웹 서비스는 공지 본문과 첨부문서에서 추출한 데이터를 기반으로 신청 일정과 제출 방법을 안내하고, 연구 목록을

검색할 수 있도록 구성하였다. 구조화 데이터를 활용한 웹 서비스의 시범 화면은 그림 7 과 같다.

본 연구에서는 개별연구 신청 공지를 대표 사례로 적용하였으나, 탐색 키워드와 문서별 추출 규칙을 추가하면 장학금 신청, 현장실습 모집, 수강신청 및 졸업요건 안내 등 다른 학사·행정 공지에도 동일한 처리 구조를 확장할 수 있다. 다만 공지별 문서 양식과 추출 대상이 다르므로, 적용 범위를 확대할 때에는 공지 유형별 키워드와 분석 규칙을 추가로 정의해야 한다.




그림 7. 구조화 데이터 활용을 위한 웹 서비스 시범 화면
Fig. 7. Prototype web interface for utilizing the structured data

6. 결론 및 향후 연구

본 연구에서는 키워드를 기반으로 관련 최신 학사 공지를 자동으로 탐색하고, 공지 본문과 Excel·HWP 첨부문서를 분석하여 구조화된 JSON 데이터로 변환하는 시스템을 구현하였다. 일반적인 웹 크롤링이 HTML 본문과 링크를 수집하는 데 중점을 두는 것과 달리, 본 시스템은 관련 공지 탐색, 첨부파일 자동 수집, 파일 형식별 분석, 주요 정보 구조화 및 이전 결과와의 변경 비교를 하나의 처리 과정으로 통합하였다.

시스템 검증을 위해 동국대학교 컴퓨터·AI 학부의 개별연구 신청 공지를 대표 사례로 적용하였다. 실행 결과 공지 1 건에서 Excel 과 HWP 첨부파일 2 개를 수집하였으며, Excel 문서에서 총 43 개의 연구 항목을 추출하였다. HWP 문서에서는 8 개의 입력 필드와 1 개의 담당교수 서명란을 확인하였고, 공지 본문에서는 신청 일정과 제출 조건을 구조화하였다. 또한 공지 탐색과 문서 분석 기능을 검증하는 Python 단위 테스트 40 개가 모두 통과하였다.

추출된 데이터는 공지, 일정, 제출 정보, 연구 목록 및 신청서 항목으로 분류하여 하나의 JSON 스냅샷으로 저장하였다. 연구내용과 수강 자격사항에서 생성한 파생 정보는 연구 목록 검색과 조건별 필터링에 활용할 수 있으며, 이전 스냅샷과의 비교 결과는 공지 수정이나 첨부파일 교체 여부를 확인하는 데 사용할 수 있다.

다만 본 연구의 실제 검증은 단일 학과의 개별연구 공지 1 건을 대상으로 수행하였으므로, 홈페이지 구조와 첨부 문서 양식이 다른 학사 공지에 대한 일반화 가능성은 추가 검증이 필요하다. 향후에는 PDF 와 HWPX 첨부문서에 대한 분석 기능을 추가하고, 문서 구조가 서로 다른 여러 학사 공지를 대상으로 적용 범위를 확대할 필요가 있다. 또한 탐색 키워드와 추출 규칙을 공지 유형별로 설정할 수 있도록 개선하고, 변경된 공지 내용을 사용자에게 안내하는 웹 서비스와 연계할 수 있다.

참 고 문 헌

- [1] Python Software Foundation, “urllib.request — Extensible Library for Opening URLs,” Python 3 Documentation, accessed July 13, 2026.
- [2] lxml Project, “Parsing XML and HTML with lxml,” lxml Documentation, accessed July 13, 2026.
- [3] Ecma International, ECMA-376: Office Open XML File Formats, 5th ed., 2021.
- [4] Hancom Inc., “HWP/OWPML File Format Specification,” accessed July 13, 2026.
- [5] T. Bray, “The JavaScript Object Notation (JSON) Data Interchange Format,” RFC 8259, Dec. 2017.